

ESCUELA COLOMBIANA DE INGENIERÍA JULIO GARAVITO
DEPARTAMENTO DE INGENIERÍA DE SISTEMAS

Sistema Predictor de Resultados en Partidos de Fútbol Español

---

Proyecto de curso PTIA

Grupo 04

Integrantes:

Juan Diego Gaitán
José Alejandro Martínez
Oscar David Lasso
Carlos Andrés Sánchez

Fecha de entrega: 09 de octubre de 2026

Declaración firmada

"Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación"

Nombre del estudiante & Firma:

Juan Diego Gaitán

Juan Diego Gaitán

Fecha: 09 de octubre de 2026

José Alejandro Martínez

José Alejandro Martínez

Fecha: 09 de octubre de 2026

Oscar David Lasso

Oscar David Lasso

Fecha: 09 de octubre de 2026

Carlos Andrés Sánchez

Carlos Andrés Sánchez

Fecha: 09 de octubre de 2026

Índice de contenido

- **1. Alcance y Objetivos**
  - 1.1. Problema que efectivamente se va a resolver
  - 1.2. Justificación de la simplificación del problema
  - 1.3. Objetivos del proyecto
    - 1.1.1. Objetivo general
    - 1.1.2. Objetivos específicos (cualitativos y cuantitativos)
- **2. Diseño metodológico**
  - 2.1. Estrategia general seleccionada para la solución y justificación
  - 2.2. Concentración de la inteligencia: conocimiento y razonamiento
  - 2.3. Herramientas seleccionadas para la implementación y justificación
  - 2.4. Arquitectura de la solución: componentes y relaciones
  - 2.5. Componente principal del sistema: descripción detallada
- **3. Bibliográficas**

Índice de Tablas

Índice de figuras

1. Alcance y Objetivos

Recomendacion

Definición de los problemas

- ¿Cuál es el problema que efectivamente van a resolver?
- b. ¿Por qué consideran que es una simplificación adecuada?
  c. ¿Cuál sería el objetivo (cuantitativo y cualitativo)? Detallar objetivo general

¿Cuál es el problema que efectivamente van a resolver?

Predecir la distribución de probabilidad pre-partido del resultado final en encuentros de fútbol de la English Premier League (EPL), clasificándolo en tres eventos mutuamente excluyentes:

- Victoria Local
- Empate
- Victoria Visitante

- Enfoque real:

No intentamos adivinar el minuto exacto de un gol ni predecir un marcador hiperespecífico (como un 3–2 o 4–1), porque en el fútbol intervienen factores fortuitos incontrolables (errores arbitrales, expulsiones tempranas, rebotes).

El problema concreto que resolvemos es: conociendo únicamente el estado de ambos equipos antes de que empiece el partido (su nivel Elo, cómo vienen jugando en los últimos 5 partidos, días de descanso y las cuotas del mercado), estimar qué tan probable es cada uno de los tres desenlaces posibles.

¿Por qué consideran que es una simplificación adecuada?

- **Es el estándar operativo del dominio (Mercado 1X2):**
  En la industria deportiva, analítica y casas de pronósticos, la toma de decisiones no depende de adivinar el número exacto de córners o disparos, sino de evaluar el mercado de 3 vías (Gana Local/ Empate / Gana Visitante). Reducir el espacio de salida a estas 3 clases elimina el ruido excesivo de predecir variables aleatorias secundarias.

- **Captura la incertidumbre real del deporte:**
  En lugar de forzar una simplificación binaria artificial (como "¿Gana el local: Sí o No?", que suele esconder el empate), conservamos la naturaleza tripartita del fútbol y calculamos probabilidades continuas que suman 100% mediante Softmax. Esto permite saber cuándo un partido es muy parejo (ej. 34% - 33% - 33%) o cuándo hay un favorito claro (60% - 25% - 15%).

- **Causalidad y viabilidad computacional:**
  En Resumir 90 minutos de juego continuo en un vector de 40 características estadísticas previas al B pitazo inicial nos permite modelar la fortaleza relativa de los clubes sin requerir datos de telemetría de jugadores en tiempo real (GPS), garantizando cero fuga de información del futuro (zero data leakage).

¿Cuál sería el objetivo (cuantitativo y cualitativo)? Detallar objetivo general

- **Objetivo General**

  Desarrollar, entrenar y validar rigurosamente una Red Neuronal Artificial Profunda (Deep Multilayer Perceptron - MLP) que estime el vector de probabilidades pre-partido para los resultados de la English Premier League, garantizando una estricta causalidad temporal (entrenada entre 2000 y 2017, validada entre 2017 y 2021, y evaluada sobre temporadas contemporáneas 2021–2025) y superando a los modelos de referencia en exactitud y fiabilidad probabilística.

  - **Objetivos Cualitativos**
    - **Cero Fuga de Información (Zero Data Leakage):**

      Garantizar rigor metodológico asegurando que ninguna variable de entrada dependa de hechos ocurridos durante o después del partido, y que el escalado de datos se ajuste exclusivamente en las temporadas de entrenamiento.

      Calibración y Confiabilidad Probabilística: Lograr que los porcentajes arrojados por la red reflejen la frecuencia empírica real de los eventos, permitiendo cuantificar el riesgo y no solo emitir una predicción rígida de "ganador".

    - **Modularidad y Usabilidad:**

      Entregar un servicio desacoplado y funcional (prediction_service.py) que permita a cualquier usuario ingresar dos equipos y una fecha para obtener el pronóstico de forma inmediata.

  - **Objetivos Cuantitativos:**
    - **Exactitud (Accuracy):** Superar el 44.70% del modelo mayoritario (Dummy).
    - **Resultado alcanzado:** 55.44% a 56.11% sobre 1.490 partidos nunca vistos (ventaja superior a 11 puntos porcentuales).
    - **Pérdida Logarítmica (Log Loss):** Lograr un valor inferior a 1.00 (frente al 1.068 del Dummy).
    - **Resultado alcanzado:** 0.955, demostrando mayor certeza en la asignación probabilística.
    - **Puntuación de Brier (Brier Score):** Reducir el error cuadrático medio a menos de 0.60.
    - **Resultado alcanzado:** 0.566 (frente al 0.646 del Dummy).
    - **Sensibilidad al Empate (F1-Score Empate):** Superar el 0.00 habitual de los modelos ingenuos en la clase minoritaria.
    - **Resultado alcanzado:** 27.16% mediante calibración Bayesiana de umbrales.

2. Diseño metodológico

Recomendaciones

- Estrategia general seleccionada para la solución y justificación
- Concentración de la inteligencia: conocimiento y razonamiento
- Herramientas seleccionadas para la implementación y justificación
- Arquitectura de la solución: componentes y relaciones
- Componente principal del sistema: descripción detallada

Estrategia general seleccionada para la solución y justificación

- **Estrategia seleccionada:**
  Modelado supervisado de clasificación multiclase (Victoria Local, Empate, Victoria Visitante) con salida probabilística continua mediante una Red Neuronal Artificial Profunda (Deep MLP), entrenada bajo partición cronológica estricta (entrenamiento 2000–2017, validación 2017–2021 y prueba 2021–2025).

- **Justificación:**
  El fútbol es un fenómeno dinámico y no lineal donde interactúan múltiples factores (calificaciones Elo, fatiga física, rachas de goles y probabilidades implícitas del mercado). Un clasificador lineal o un perceptrón simple no puede capturar estas relaciones cruzadas. La partición temporal estricta garantiza cero fuga de información hacia el futuro, simulando con precisión las condiciones reales de pronóstico.

Concentración de la inteligencia: conocimiento y razonamiento

- **Conocimiento: Se concentra en dos elementos:**

  El vector de 40 características pre-partido obtenido al fusionar las tres fuentes de datos (clasificaciones Elo, rachas de 3 y 5 partidos, métricas rodantes de goles y tiros, días de descanso, historial directo y cuotas de Bet365).

  Los pesos y sesgos sinápticos aprendidos por la red neuronal y almacenados en sus capas densas tras la optimización con Backpropagation.

- **Razonamiento:**

  Ocurre durante la propagación hacia adelante (Forward Propagation), donde la red transforma las características de entrada mediante capas no lineales sucesivas (ReLU, Batch Normalization y Dropout) para mapearlas a un vector de tres probabilidades continuas que suman 100% mediante Softmax. El sistema razona sobre la distribución continua de probabilidades para cuantificar el riesgo de cada desenlace, permitiendo aplicar umbrales de decisión calibrados en lugar de imponer una etiqueta rígida.

Herramientas seleccionadas para la implementación y justificación

- **Herramientas:**

  Python como lenguaje base; TensorFlow y Keras para la construcción y entrenamiento de la red neuronal profunda; Scikit-Learn para el escalado de variables (StandardScaler), los modelos de referencia (Dummy, Regresión Logística, HistGradientBoosting) y el cálculo de métricas; Pandas y NumPy para la manipulación y cruce de datos; Matplotlib y Seaborn para las visualizaciones analíticas.

- **Justificación:**

  Keras ofrece una API modular y robusta para diseñar arquitecturas profundas incorporando técnicas modernas de regularización (Dropout, decaimiento L2, Batch Normalization) y mecanismos de parada temprana (EarlyStopping). Scikit-learn complementa el desarrollo proporcionando el estándar académico para comparar la red neuronal contra modelos base bajo exactamente las mismas métricas de evaluación.

Arquitectura de la solución: componentes y relaciones

La solución se estructura en cinco módulos secuenciales e interconectados:

- **Módulo de Ingesta y Fusión:**
  Carga los tres archivos tabulares (9.380 partidos), normaliza discrepancias en los nombres de los clubes y realiza el cruce relacional de las fuentes.

- **Módulo de Ingeniería de Características:**
  Construye las 40 variables numéricas pre-partido asegurando causalidad temporal estricta anterior al pitazo inicial.

- **Módulo de Preprocesamiento y Partición:**
  Divide los datos cronológicamente y aplica estandarización (StandardScaler) calculada exclusivamente sobre el conjunto de entrenamiento.

- **Módulo de Aprendizaje Profundo:**
  Construye y entrena la red neuronal profunda multiclase, monitorea las curvas de pérdida y exactitud, y evalúa el desempeño frente a los baselines sobre el conjunto de prueba contemporáneo.

- **Módulo de Servicio Predictivo (prediction_service.py):**
  Encapsula el modelo y el escalador para ofrecer inferencia interactiva sobre nuevos partidos, resolviendo alias de equipos y cuotas pre-partido.

Componente principal del sistema: descripción detallada

- **Componente principal:**
  Red Neuronal Artificial Profunda (Deep MLP Multiclase), serializada en models/best_deep_mlp.keras.

  - **Descripción técnica:**

    - **Capa de Entrada**: 40 neuronas correspondientes a las características numéricas normalizadas.

    - **Capa Oculta 1:** 128 neuronas con activación ReLU, regularización L2 (1e-4), Batch Normalization y Dropout del 25%.

    - **Capa Oculta 2:** 64 neuronas con activación ReLU, regularización L2 (1e-4), Batch Normalization y Dropout del 20%.

    - **Capa Oculta 3:** 32 neuronas con activación ReLU, regularización L2 (1e-4) y Dropout del 15%.

    - **Capa Oculta 4:** 16 neuronas con activación ReLU como embudo de representación de alto nivel.

    - **Capa de Salida:** 3 neuronas con activación Softmax que generan las probabilidades normalizadas de Victoria Local, Empate y Victoria Visitante.

    - **Compilación y Entrenamiento:** Función de pérdida Categorical Cross-Entropy, optimizador Adam (tasa de aprendizaje 0.001) y control de sobreajuste mediante EarlyStopping y ReduceLROnPlateau.

3. Referencias Bibliográficas

1. Marco General y Estado del Arte

- Taye, M. M. (2023). Understanding of Machine Learning with Deep Learning: Architectures, Workflow, Applications and Future Directions. Computers, 12(5), 91. https://doi.org/10.3390/computers12050091

2. Fundamentos de Deep Learning y Redes Neuronales Profundas

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. https://www.deeplearningbook.org/

- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating deep network training by reducing internal covariate shift. En F. Bach & D. Blei (Eds.), Proceedings of the 32nd International Conference on Machine Learning (Vol. 37, pp. 448–456). PMLR. https://proceedings.mlr.press/v37/ioffe15.html

- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv. https://doi.org/10.48550/arXiv.1412.6980

- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444. https://doi.org/10.1038/nature14539

- Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines. En J. Fürnkranz & T. Joachims (Eds.), Proceedings of the 27th International Conference on Machine Learning (ICML-10) (pp. 807–814). Omnipress.

- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15(1), 1929–1958. http://jmlr.org/papers/v15/srivastava14a.html

3. Predicción Deportiva y Machine Learning en Fútbol

- Baboota, R., & Kaur, H. (2019). Predictive analysis and modelling football results using machine learning approach for English Premier League. International Journal of Forecasting, 35(2), 741–755. https://doi.org/10.1016/j.ijforecast.2018.01.003

- Berrar, D., Lopes, P., & Dubitzky, W. (2019). Incorporating domain knowledge in machine learning for soccer outcome prediction. Machine Learning, 108(1), 97–126. https://doi.org/10.1007/s10994-018-5747-8

- Bunker, R., & Thabtah, F. (2019). A machine learning framework for sport result prediction. Applied Computing and Informatics, 15(1), 27–33. https://doi.org/10.1016/j.aci.2017.09.005

- Dixon, M. J., & Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. Journal of the Royal Statistical Society: Series C (Applied Statistics), 46(2), 265–280. https://doi.org/10.1111/1467-9876.00065

- Hubáček, O., Šourek, G., & Železný, F. (2019). Learning to predict soccer results from relational data with gradient boosted trees. Machine Learning, 108(1), 29–47. https://doi.org/10.1007/s10994-018-5704-6

4. Calibración Probabilística y Métricas de Evaluación

- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. Monthly Weather Review, 78(1), 1–3. https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

- Elo, A. E. (1978). The Rating of Chessplayers, Past and Present. Arco Publishing.

- Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En D. Precup & Y. W. Teh (Eds.), Proceedings of the 34th International Conference on Machine Learning (Vol. 70, pp. 1321–1330). PMLR. https://proceedings.mlr.press/v70/guo17a.html

- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. En Proceedings of the 22nd International Conference on Machine Learning (ICML-05) (pp. 625–632). Association for Computing Machinery. https://doi.org/10.1145/1102351.1102430

}

5. Trabajos Previos y Antecedentes del Grupo (Hito 1)

- Grupo de Trabajo PTIA. (2024). Propuesta de proyecto y definición de preguntas de investigación (Hito 1) [Documento de trabajo no publicado]. Escuela Colombiana de Ingeniería Julio Garavito.

6. Datasets y Fuentes de Datos Integradas

- Gbor, A. (2025). Club football match data 2000-2025 [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/adamgbor/club-football-match-data-2000-2025

- Hui, M. (2025). English Premier League (EPL) match data 2000-2025 [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/marcohuiii/english-premier-league-epl-match-data-2000-2025

- Nazarenka, A. (2023). Premier League [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/ajaxianazarenka/premier-league

7. Bibliografía Oficial del Curso (PTIA - ECI)

- Escuela Colombiana de Ingeniería Julio Garavito. (2024). Programa académico y guía docente: Proyecto Transversal en Inteligencia Artificial (PTIA) - Semana 1 [Material de clase].

- Nilsson, N. J. (1982). Principles of Artificial Intelligence. Springer-Verlag. https://doi.org/10.1007/978-3-662-09438-9

- Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4.ª ed.). Pearson.

- Winston, P. H. (1992). Artificial Intelligence (3.ª ed.). Addison-Wesley.